OCR projet 9 - Exercice 1 - Modéliser une infrastructure hybride dans le cloud

Mathilde LE SOLLIEC

Contexte

InduTech Data, spécialisée en analyse de données industrielles, a récemment intégré des solutions IoT (objet connecté : capteur…). Cela génère un volume de données croissant que son datacenter actuel ne peut plus absorber (augmentation mensuelle de 50 Go de données en temps réel, principalement des flux continus de capteurs nécessitant un traitement rapide et fiable.)

Problème : limites de capacité et de performance de l'infrastructure on-premise.

Objectif :

- Moderniser la gestion des données en :
  - une intégration on-premise ↔ cloud (architecture hybride)
  - Intégrant un moteur de streaming (Redpanda) pour les flux temps réel
  - Migration partielle vers le cloud (AWS) pour la scalabilité et la performance
  - maintien d'une infrastructure locale pour la gestion des identités

Environnement SI actuel (infrastructure on-premise) :

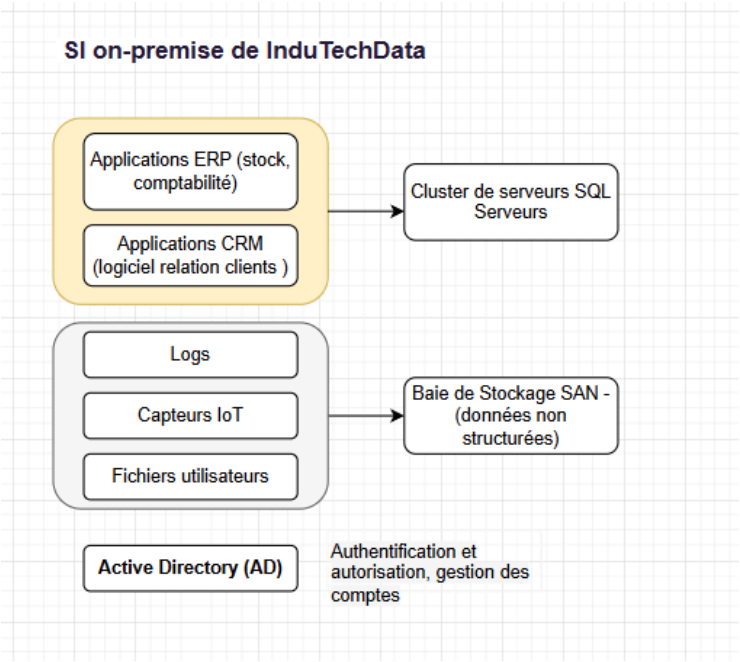

Pour atteindre cette objectif, les étapes réalisées sont les suivantes :

Contexte

Etape 1 : Identification et sélection des composants cloud

- REDPANDA
- Amazon S3
- Amazon Redshift
- AWS Directory Service

Etape 2 : Représentation visuelle de l'infrastructure hybride

- 2.1. Schéma de l'infrastructure hybride
- 2.2. Zoom : les flux de données critiques
- 2.3 Haute disponibilité et plan de reprise

Étape 3 - Évaluez la compatibilité avec l'environnement SI existant

- 3.1 Les accès utilisateurs
- 3.2 Sécurisation des transferts de données
- 3.2 Comptabilité
- 3.3 Estimation des coûts
- 3.4 Scalabilité

Etape 1 : Identification et sélection des composants cloud

La première étape consiste à identifier et sélectionner les composants cloud les plus adaptés aux besoins techniques et compatibles avec les services REDPANDA.

Les composants clouds choisis doivent répondrent à 4 besoins :

- Le traitement des données en temps réel (streaming)
- Le stockage de données non structurées
- L'entrepôt de données
- La sécurisation et gestion des accès

Besoins	Usage	Service Cloud	Justification du choix	Alternatives
Traitement des données en temps réel (streaming)	Orchestrer les flux de données.	**REDPANDA**	Simplicité d'installation, faible consommation de ressources et Fonctionnalités intégrées pour orchestrer les flux de données - traitement des flux IoT et des logs.	Apache Kafka (plus lourd à administrer - Redpanda est retenu pour sa légèreté opérationnelle)
Stockage de données non structurées	Service de stockage d'objets dans le cloud, pour héberger les données non structurées	**Amazon S3**	Scalabilité, sécurité, et interopérabilité avec Redpanda	Google Cloud Storage (externe à AWS)
Entrepôt de données	Centraliser les données analytiques et de supporter des requêtes SQL complexes	**Amazon Redshift**	Entrepôt analytiques - supporte les requêtes SQL complexes Synchronisation des bases SQL Server on-premise avec la solution cloud choisie : via AWS DMS (réplication)	Snowflake BigQuery (externes à AWS)
Sécurisation et gestion des accès	Etendre l'Active Directory on-premise au cloud.	**AWS Directory Service**	Gestion unifiée des identités et des permissions sur l'ensemble de l'infrastructure.	Azure Active Directory (externe à AWS)

Etape 2 : Représentation visuelle de l'infrastructure hybride

2.1. Schéma de l'infrastructure hybride

L'architecture proposé est une architecture hybride AWS:

- consolidant les données brutes dans S3 comme source unique immuable,
- utilisant Redshift pour l'analytique en deux flux distincts (SQL nightly + IoT real-time),
- Redpanda pour l'ingestion streaming,
- et Directory Service pour l'identité unifiée.

Le cloud ajoute : flexibilité, analytique avancée, supervision (CloudWatch), gestion centralisée des identités (IAM + Directory Service).

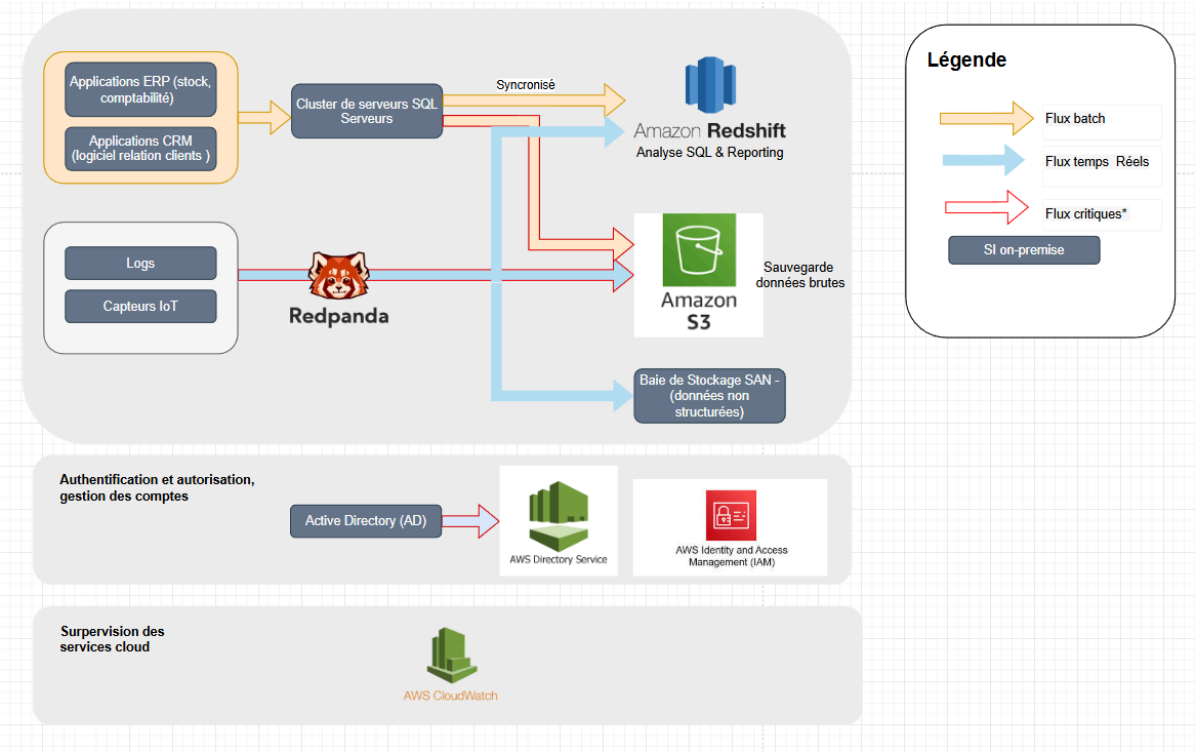

Les composant SQL server et Baie SAN sont toujours hébergés on-premise :

- SQL server (ERP/CRM, données structurées) : Production critique, données sensibles, contrôle et performance locale
- Baie SAN (données non structurées, logs bruts) :Volume important, accès rapide pour applications locales, sauvegardes locales

2.2. Zoom : les flux de données critiques

Flux CRITIQUES (backups + identités)

- Flux 2 : Redpanda → S3 (IoT backup brut)
- Flux 4 : SQL Server → S3 (métier backup brut)
- Flux 6 : AD ↔ Directory Service (identités SSO)

Critique car : perte données ou perte accès utilisateurs

Flux NON-CRITIQUES (analytique + monitoring)

- Flux 3 : Redpanda → Redshift (aggregations, recalculable)
- Flux 5 : SQL Server → Redshift (analytics, recalculable)
- Flux 7 : Services → CloudWatch (observability, facultatif)

➜ Ces flux peuvent échouer court-terme sans perte données (recalculables depuis Flux 2, 4, 6)

Pour envoyer les données :

- Depuis SQL server : AWS Data Migration Service ou scripts ETL personnalisés (ou outils tiers comme AirFlow)
- L'interopérabilité est assurée via des connecteurs Kafka compatibles Redpanda (Kafka Connect), permettant la synchronisation des flux entre SQL Server, S3 et Redshift.

2.3 Haute disponibilité et plan de reprise

Pour garantir la continuité de service et éviter toute perte de données, plusieurs mécanismes peuvent être mis en place :

- Redshift en Multi-AZ : les données sont répliquées sur plusieurs zones de disponibilité AWS afin d'assurer la continuité en cas de panne d'un centre de données.

- Réplication S3 : les fichiers stockés dans S3 peuvent être copiés automatiquement vers une autre région AWS pour éviter toute perte en cas d'incident majeur.

- Sauvegardes Redpanda : des sauvegardes régulières des flux et configurations sont réalisées afin de pouvoir restaurer le service rapidement.

Étape 3 - Évaluez la compatibilité avec l'environnement SI existant

3.1 Les accès utilisateurs

C'est l'annuaire central de l'entreprise : il gère les identités, authentifications et permissions pour tous les utilisateurs et serveurs locaux. Il permet de savoir qui peut accéder à quoi dans l'infrastructure interne (ERP, CRM, fichiers, applications).
C'est le service cloud qui reproduit ou étend les fonctionnalités de l'AD dans AWS. Les utilisateurs se connectent aux applications cloud avec leurs identifiants AD existants.

- AD = gestion des identités
- AWS Directory Service = pont entre AD et AWS

Les rôles et permissions AWS sont géré par IAM = gestion fine des permissions sur les services cloud. On associe les groupes AD à un rôle IAM.

La gestion est unifiée parce que :

- L'identité reste centralisée dans l'Active Directory on-premise (via AWS Directory Service).
  → Un seul compte utilisateur, un seul mot de passe.

- Les groupes AD sont associés à des rôles IAM dans AWS.
  → Les permissions cloud sont attribuées automatiquement selon le groupe.

3.2 Sécurisation des transferts de données

Redpanda et les services cloud AWS peuvent garantir une protection des flux sensibles pendant leur transfert en utilisant SSL/TLS, qui chiffre les données en transit pour les protéger contre l'interception ou la modification.

3.2 Comptabilité

Les données de **SQL Server** :

- sont transférées vers un bucket S3 via AWS DMS ou des ETL personnalisés.
- sont également copiées dans Redshift via ETL ou la commande COPY depuis S3.

Les données **de Redpanda** :

- sont envoyées vers S3 et vers Redshift grâce à Kafka Connect Sink.

L'Active Directory on-premise est relié à AWS Directory Service, puis les groupes AD sont mappés à des rôles IAM pour accéder à S3 et Redshift (Au lieu de gérer les droits utilisateur par utilisateur, on travaille par groupes)

3.3 Estimation des coûts

Avant migration, l'infrastructure on-premise impliquait des coûts d'investissement matériel, de maintenance et d'énergie. La migration vers le cloud permet un modèle basé sur l'usage et améliorant la scalabilité.

L'estimation des coûts a été estimée au regard des volumes de données existants (40 To SQL Server, 10 To SAN, +50 Go/mois IoT) et des services cloud sélectionnés.

Le calculateur AWS Pricing Calculator et https://www.redpanda.com/data-streaming/price-estimator ont été consultés, et ont permis d'extraire les informations suivantes :

Composant	Base du calcul	Estimation du besoin	Coût mensuel	Scalabilité
Redshift	Nombre de noeud Ou à l'usage (**Redshift Serverless**)	Besoin d'une instance - 1 noeud	**4 292,40 USD**	Si capacité dépassée → Redshift Managed Storage alloue automatiquement du stockage supplémentaire (0,02 USD/Go) Possibilité d'ajouter des noeuds
S3	Go stockés par mois 0,024 USD/Go/mois	Réplication : 50 To (40 To SQL Server + 10 To SAN) Migration progressive ?	**1 228,80 USD** (50To x 0,024 USD/go)	Scalabilité illimitée, automatique
Redpanda	Dépend du volume de données et du nombre de consommateurs Débit : MB/s	1 MB/s (50 Go/mois → 1,7 Go/jour → 20 Ko/s → débit)	**488,78 USD**	Ajout de nœuds possible
AWS Directory Service	Nombre de répertoire	1 répertoire	**127,75 USD**	Gestion unifiée des identités et permissions ; extension automatique pour le cloud
CloudWatch	Nombre de métriques	Si standard gratuit	**50-150 USD/mois**	Peut passer à des métriques détaillées ou personnalisées
Total			**6 137,73 USD**	

Paiement à l'usage pour :

- Le stockage (S3, Redshift…)
- Le traitement/instances (Redpanda sur EC2, Redshift compute nodes)
- Le transfert de données

Les coûts sont surveillés à travers CloudWatch et AWS Cost Explorer. Des alertes budgétaires peuvent être mises en place.

3.4 Scalabilité

Scalabilité technique :

- S3 est illimité et ne nécessite aucune action,
- que Redshift permet d'ajouter des nœuds à chaud via Elastic Resize,
- Redpanda scale horizontalement en ajoutant des brokers sans interruption de service.

Projection à 12 mois : L’augmentation de G0 de données temps réel supplémentaires est gérable sans modification majeure de l'architecture.